

Évaluation du biais et de la variance bootstrap appliqué aux données imputées

1. Introduction

Dans la recherche appliquée, les valeurs manquantes représentent un défi courant dans l'analyse des données. Pour résoudre ce problème et maximiser l'utilisation des données disponibles, des méthodes d'imputation sont souvent employées. Cependant, l'application du bootstrap aux données imputées soulève certaines questions. Plus précisément, il n'est pas clair dans quelle mesure le biais et la variance de l'estimateur de variance (s^2) peuvent être correctement estimés au niveau du bootstrap. Certaines recherches traitent de l'utilisation de l'imputation combinée au bootstrap. Par exemple, Schomaker et Heumann ont examiné divers scénarios d'intégration de l'imputation dans le processus de bootstrap et évalué les taux de couverture [1]. Bartlett et Hughes ont exploré la validité de l'utilisation des méthodes bootstrap avec l'imputation multiple, en particulier lorsque les modèles d'imputation et d'analyse sont mal spécifiés [2]. Cependant, aucune de ces études n'aborde directement la question de savoir si le bootstrap peut reproduire le biais et la variance de l'estimateur de variance.

Pour répondre à cette question, nous menons une étude de simulation en considérant différentes tailles d'échantillon et niveaux de données manquantes, notamment des tailles d'échantillons de 40 et 100, ainsi que des probabilités de manquement de 0,1, 0,2 et 0,3. Nous créons des ensembles de données en tenant compte de la structure d'un modèle de régression linéaire multivarié, dont les covariables sont choisies arbitrairement. Pour générer les valeurs manquantes dans notre variable dépendante, nous utilisons le mécanisme Missing Completely At Random (MCAR) pour des raisons de simplicité, où la probabilité de données manquantes ne dépend ni des données observées, ni des données non observées.

Comme méthode d'imputation, nous sélectionnons l'imputation par le Single Predictive Mean Matching (SPMM), qui utilise les données observées pour ajuster un modèle et choisit les valeurs imputées à partir des observations originales en fonction des résultats prédits. Cette méthode est choisie car elle respecte davantage les observations originales et leur distribution, comparée à des approches plus simples comme l'imputation par la moyenne ou la médiane. Nous calculons ensuite le biais et la variance de s^2 à partir des ensembles de données incluant les observations imputées. Au niveau du bootstrap, les valeurs manquantes sont incluses dans chaque échantillon bootstrap et ces observations sont réimputées par SPMM. À partir de cet échantillon bootstrap imputé, nous obtenons des estimateurs du biais et de la variance de s^2 .

Pour évaluer la précision de ces estimations, le biais absolu est introduit pour l'évaluation du biais et le biais relatif est introduit pour l'évaluation de la variance. Nos résultats montrent que pour l'estimation du biais, le bootstrap performe bien lorsque la probabilité de données manquantes (p) est inférieure ou égale à 0,2. Pour l'estimation de la variance, le biais relatif montre une performance améliorée à mesure que la probabilité de données manquantes augmente, quelle que soit la taille de l'échantillon. Nos résultats globaux suggèrent que la probabilité de manquement et la taille d'échantillon ont un grand impact sur la fiabilité de nos estimateurs.

Ce rapport est organisé comme suit : la Section 2 présente les préliminaires, y compris la sélection du modèle et des estimateurs choisis. La Section 3 explique le mécanisme des données manquantes. La Section 4 discute de la méthode d'imputation par SPMM. La Section 5 décrit la procédure de bootstrap. La Section 6 détaille la structure de la simulation. La Section 7 présente les résultats. La Section 8 résume nos résultats.

2. Préliminaires

2.1 Modèle de régression

Dans cet article, notre modèle de régression a la forme suivante :

$$y = X\beta + \epsilon \quad (1)$$

où ϵ est un vecteur de n erreurs indépendantes et identiquement distribuées (i.i.d.), suivant une loi F de moyenne 0 et de variance σ^2 , X est une matrice n par p de valeurs fixes, et β est un vecteur de dimension p de constantes inconnues. Ainsi, y représente un vecteur de n observations.

2.2 Paramètre d'intérêt et estimateur

Notre paramètre d'intérêt est la variance de notre population, mais comme notre modèle inclut des variables X qui sont fixes, alors nous ne connaissons pas la variance de la population. Étant donné que nos ϵ sont i.i.d., nous calculons la variance de la population en prenant la variance des observations y du modèle, comme suit :

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (y_i - \bar{y})^2 \quad (2)$$

où y_i représente la i -ème observation de notre population, $\bar{y} = \frac{1}{N} \sum_{i=1}^N y_i$ est la moyenne des y_i et $N = n$ est le nombre total d'observations.

Après l'application du mécanisme de manquement MCAR, qui sera décrit dans la Section 3 à nos observations y , nous aurons des observations manquantes qui seront imputées par le SPMM, qui sera décrit dans la Section 4. Notre estimateur de la variance de la population est donc la variance de notre échantillon imputé, qui est définie comme suit:

$$s_{imp}^2 = \frac{1}{n-1} \sum_{i=1}^n (y_{imp;i} - \bar{y}_{imp})^2 \quad (3)$$

où $y_{imp;i}$ représente la i -ème observation de notre échantillon imputé par le SPMM et $\overline{y_{imp}} = \frac{1}{n} \sum_{i=1}^n y_{imp;i}$. Sur la base de ce modèle, nous expliquons le mécanisme de manquement, la méthode d'imputation et la méthode bootstrap.

3. Données manquantes

Rubin a classifié les valeurs manquantes en trois mécanismes: Missing Completely at Random (MCAR), Missing at Random (MAR) et Missing Not at Random (MNAR). Le scénario dans lequel les données manquantes se produisent indépendamment de toute autre variable du jeu de données est connu sous le nom de MCAR [3]. Dans cette recherche, nous avons choisi le mécanisme MCAR pour sa simplicité.

Dans le cadre de la génération de données MCAR avec un schéma de données manquantes univarié, supposons que chaque observation ait une probabilité p d'avoir des valeurs manquantes pour la variable cible y . Cette règle peut être exprimée par :

$$P(A = 1) = p$$

où A est l'indicateur des données manquantes et p représente la probabilité qu'une donnée soit manquante. Soit A_i , une variable indicatrice qui désigne le manquement de l'observation y_i , où $A_i = 1$ indique que y_i manque et $A_i = 0$ indique que y_i est observable. Sous cette règle, la proportion attendue de valeurs manquantes et le nombre de sujets avec des données manquantes peuvent être dérivés. Étant donné n sujets, soit A la variable aléatoire comptant les sujets avec des valeurs manquantes. En supposant que le caractère de manquement de chaque sujet est indépendant, A suit une distribution binomiale [4] :

$$A \sim \text{Bin}(n, p)$$

Par ce mécanisme, nous appliquons des valeurs manquantes dans notre modèle. Dans notre modèle, nous avons n observations, et chaque observation sera associée à un indicateur A_i qui détermine si la donnée correspondante est manquante ou non :

$$\begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ \vdots \\ y_n \end{bmatrix} \begin{bmatrix} A_1 \\ A_2 \\ A_3 \\ \vdots \\ \vdots \\ A_n \end{bmatrix}$$

où $i = 1, \dots, n$. Ainsi, le vecteur $y = [y_1, y_2, \dots, y_n]^T$ contiendra à la fois des observations manquantes et non manquantes, selon les valeurs des indicateurs A .

$$\begin{aligned}
\begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_n \end{bmatrix} \begin{bmatrix} 0 \\ 1 \\ 1 \\ \vdots \\ 0 \end{bmatrix} & \text{Sans perte de généralité} = \begin{bmatrix} y_1 \\ \vdots \\ y_n \\ y_2 \\ y_3 \\ \vdots \end{bmatrix} \begin{bmatrix} 0 \\ \vdots \\ 0 \\ 1 \\ 1 \\ \vdots \end{bmatrix} = \begin{bmatrix} y_{1obs} \\ \vdots \\ y_{nobs} \\ y_{1man} \\ \vdots \\ y_{nman} \end{bmatrix} \\
y = \begin{bmatrix} y_{obs} \\ y_{man} \end{bmatrix} &= \begin{bmatrix} y_{1obs} \\ \vdots \\ y_{nobs} \\ y_{1man} \\ \vdots \\ y_{nman} \end{bmatrix} = \begin{bmatrix} X_{11} & \cdots & X_{1p} \\ \vdots & \ddots & \vdots \\ X_{nobs1} & \cdots & X_{nobs p} \\ X_{nobs+11} & \cdots & X_{nobs+1p} \\ \vdots & \ddots & \vdots \\ X_{n1} & \cdots & X_{np} \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_p \end{bmatrix} + \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{bmatrix} \\
\begin{bmatrix} X_{11} & \cdots & X_{1p} \\ \vdots & \ddots & \vdots \\ X_{nobs1} & \cdots & X_{nobs p} \\ X_{nobs+11} & \cdots & X_{nobs+1p} \\ \vdots & \ddots & \vdots \\ X_{n1} & \cdots & X_{np} \end{bmatrix} &= \begin{bmatrix} X_{obs} \\ X_{man} \end{bmatrix}
\end{aligned}$$

où y_{obs} représentent les observations de y non manquantes, y_{man} représentent les observations de y manquantes et X_{obs} représentent les valeurs de X pour les observations non manquantes, X_{man} représentent les valeurs de X pour les observations manquantes. Nous avons $n_{obs} + n_{man} = n$, où n_{obs} représente le nombre d'observations non manquantes dans y et n_{man} représente le nombre d'observations manquantes dans y .

4. Single Predictive Mean Matching

La méthode d'imputation utilisée pour traiter les données manquantes est le Single Predictive Mean Matching (SPMM) [5]. Après l'application du mécanisme MCAR à nos n observations, nous obtenons un certain nombre de données manquantes et non manquantes. Pour imputer ces données manquantes par le SPMM, nous procédons d'abord à une régression des y_{obs} sur les X_{obs} en utilisant la méthode des moindres carrés :

$$\hat{\beta}_{obs} = (X_{obs}^T X_{obs})^{-1} X_{obs}^T y_{obs}$$

où X_{obs}^T est la transposée de X_{obs} . Nous obtenons les valeurs prédites pour y_{obs} et y_{man} à partir de $\hat{\beta}_{obs}$:

$$\hat{y} = X \hat{\beta}_{obs} = \begin{bmatrix} X_{obs} \\ X_{man} \end{bmatrix} \hat{\beta}_{obs} = \begin{bmatrix} \hat{y}_{obs} \\ \hat{y}_{man} \end{bmatrix}$$

où $\hat{y}_{obs}$ représentent les valeurs prédites pour les observations non manquantes et $\hat{y}_{man}$ représentent les valeurs prédites pour les observations manquantes. Pour chaque valeur prédite

de $\hat{y}_{man}$, nous cherchons la valeur prédite d'une observation non manquante qui minimise la distance avec $\hat{y}_{man}$:

$$\hat{j}(i) = \operatorname{argmin} |\hat{y}_{obs;j} - \hat{y}_{man;i}|$$

où $j = 1, \dots, n_{obs}$ et $i = 1, \dots, n_{man}$. Pour imputer les valeurs manquantes $y_{man;i}$ nous utilisons l'observation originale $y_{obs;\hat{j}(i)}$ dont la valeur prédite minimise la distance avec $\hat{y}_{man;i}$:

$$y_{man;i}^{imp} = y_{obs;\hat{j}(i)}$$

où $y_{man;i}^{imp}$ représente la i -ème valeur manquante imputée et $y_{obs;\hat{j}(i)}$ représente l'observation originale de y pour laquelle sa valeur prédite minimise la distance avec $\hat{y}_{man;i}$. Ainsi, le vecteur des données imputées devient :

$$y_{imp} = \begin{bmatrix} y_{obs} \\ y_{man}^{imp} \end{bmatrix}$$

où y_{man}^{imp} représentent les observations manquantes qui ont été imputées. Ainsi, nous obtenons un vecteur d'observations de longueur n , comprenant les valeurs observées et les valeurs imputées.

5. Bootstrap

5.1 Bootstrap des données manquantes

Pour effectuer un bootstrap sur les données manquantes, nous rééchantillonons les données, qui sont un mélange d'observations non manquantes, y_{obs} , et d'observations manquantes, y_{man} . Soit B le nombre d'échantillons bootstrap. Nous obtenons B échantillons de y , chacun ayant une taille n , avec des valeurs provenant de y_{obs} et y_{man} , comme suit :

$$y_b^* = \begin{bmatrix} y_1^* \\ \vdots \\ y_n^* \end{bmatrix} = \begin{bmatrix} y_{obs;b}^* \\ y_{man;b}^* \end{bmatrix} = \begin{bmatrix} y_{1obs^*;b}^* \\ \vdots \\ y_{nobs^*;b}^* \\ y_{1man^*;b}^* \\ \vdots \\ y_{nman^*;b}^* \end{bmatrix}$$

où $b = 1, \dots, B$, y_b^* représente le b -ème échantillon bootstrap. Les indices y_1^* et y_n^* peuvent correspondre à des données observables provenant de y_{obs} ou à des données manquantes provenant de y_{man} . $y_{obs;b}^*$ représentent les observations non manquantes de y_b^* , et $y_{man;b}^*$ représentent les observations manquantes de y_b^* . Nous avons $n_{obs;b}^* + n_{man;b}^* = n$, où $n_{obs;b}^*$ est le nombre d'observations non manquantes dans y_b^* et $n_{man;b}^*$ est le nombre d'observations manquantes dans y_b^* .

5.2 Imputation au niveau Bootstrap

Pour imputer au niveau bootstrap, nous appliquons le SPMI comme décrit dans la Section 4. Nous effectuons d'abord une régression des $y_{obs;b}^*$ sur les X_{obs} par la méthode des moindres carrés. Ensuite, nous obtenons des valeurs prédites pour $y_{obs;b}^*$ et $y_{man;b}^*$ à partir de $\hat{\beta}_{obs}^*$ pour cet échantillon bootstrap et nous imputons les valeurs manquantes $y_{man;b}^*$ en utilisant l'observation, $y_{obs;b}^*$, dont sa valeur prédite minimise la distance avec la valeur prédite de $y_{man;b}^*$. Le vecteur des données imputées au niveau bootstrap devient :

$$y_{imp;b}^* = \begin{bmatrix} y_{obs;b}^* \\ y_{man;b}^{imp*} \end{bmatrix}$$

où $y_{man;b}^{imp*}$ représentent les valeurs manquantes imputées du b -ème échantillon bootstrap et $y_{obs;b}^*$ représentent les valeurs non manquantes du b -ème échantillon bootstrap. Le vecteur $y_{imp;b}^*$ contient ainsi des valeurs observées et des valeurs imputées pour chaque échantillon bootstrap.

5.3 Estimateur Bootstrap de la variance

Après l'imputation par SPMI, nous estimons la distribution de l'estimateur de la variance, s_{imp}^2 , par le bootstrap. L'estimation bootstrap de la distribution de s_{imp}^2 est calculée en prenant la variance de chaque échantillon bootstrap comme suit :

$$s_{imp;b}^{2*} = \frac{1}{n-1} \sum_{i=1}^n (y_{imp;b;i}^* - \overline{y_{imp;b}^*})^2 \quad (4)$$

où $y_{imp;b;i}^*$ représente la i -ème observation de l'échantillon imputé b du bootstrap et $\overline{y_{imp;b}^*} = \frac{1}{n} \sum_{i=1}^n y_{imp;b;i}^*$. Nous obtenons une distribution d'estimateur bootstrap de s_{imp}^2 , $s_{imp}^{2*} = [s_{imp;1}^{2*}, \dots, s_{imp;B}^{2*}]^T$.

6. Simulation

6.1 Modèle de Régression dans la Simulation

Pour cette simulation, nous générons des données basées sur notre modèle décrit par l'équation (1). La matrice X , est de taille n par 3 et chaque colonne de cette matrice est obtenue en générant n variables aléatoires suivant une loi normale standard $N(0,1)$. Cette matrice X restera fixe tout au long de la simulation. Nous choisissons $\beta = [1, 13, -2]^T$, un vecteur de longueur 3, et ϵ un vecteur de n variables aléatoires suivant une loi normale $N(0,4)$.

Pour évaluer la performance de notre estimateur bootstrap en fonction de la taille d'échantillon et de la probabilité de manquement, nous comparons deux tailles d'échantillons, $n = 40$ et $n = 100$,

et trois probabilités de manquement $p = 0,1$, $p = 0,2$, et $p = 0,3$. Ainsi, nous avons six combinaisons possibles, que l'on récapitule dans le Tableau 1.

Tableau 1. La combinaison de la taille de l'échantillon et de la probabilité de manquement

Combinaison	n	p
1	40	0,1
2	40	0,2
3	40	0,3
4	100	0,1
5	100	0,2
6	100	0,3

Abréviations: n = Taille d'échantillon, p = Probabilité de manquement

Pour chaque combinaison, nous créons $M = 1000$ jeux de données. Par conséquent, le paramètre, σ^2 , introduit dans l'équation (2) devient :

$$\sigma^2 = \frac{1}{M \cdot n} \sum_{m=1}^M \sum_{i=1}^n (y_{m;i} - \bar{y})^2$$

où $y_{m;i}$ représente la i -ème observation d'un jeu de données m et $\bar{y} = \frac{1}{Mn} \sum_{m=1}^M \sum_{i=1}^n y_{m;i}$ représente la moyenne de toutes les observations.

Nous appliquons le MCAR comme expliqué dans la Section 3 à chaque jeu de données, et imputons les données manquantes pour chaque jeu de données par le SPMM décrit dans la Section 4. Après l'imputation des données, nous appliquons la formule de la variance (de l'équation 3) mais ajustée pour les M jeux de données. Nous avons M estimateurs de la variance σ^2 , dénotés $s_{imp;m}^2$. L'estimateur de σ^2 est calculé pour chaque jeu de données comme suit :

$$s_{imp;m}^2 = \frac{1}{n-1} \sum_{i=1}^n (y_{imp;m;i} - \overline{y_{imp;m}})^2$$

où $y_{imp;m;i}$ représente la i -ème observation d'un échantillon m , imputé par le SPMM et $\overline{y_{imp;m}} = \frac{1}{n} \sum_{i=1}^n y_{imp;m;i}$. Nous obtenons, $s_{imp}^2 = [s_{imp;1}^2, \dots, s_{imp;M}^2]^T$ qui est la distribution des estimateurs de σ^2 .

La variance des estimateurs de σ^2 est obtenue en calculant la variance de s_{imp}^2 , comme suit :

$$Var(s_{imp}^2) = \frac{1}{M-1} \sum_{m=1}^M (s_{imp;m}^2 - \overline{s_{imp}^2})^2$$

où $\overline{s_{imp}^2} = \frac{1}{M} \sum_{m=1}^M s_{imp;m}^2$.

6.2 Bootstrap dans la simulation

Nous appliquons le bootstrap sur nos M jeux de données, comme décrit dans la Section 5.1. Pour chaque échantillon bootstrap, nous appliquons le SPM pour imputer les observations manquantes rééchantillonnées, comme décrit dans la Section 5.2.

Après l'imputation des données, nous appliquons la formule de la variance (de l'équation 4) pour obtenir des estimateurs bootstrap de la distribution de chaque $s_{imp;m}^2$. Ainsi, l'estimateur de $s_{imp;m}^2$, est calculé pour chaque échantillon bootstrap comme suit :

$$s_{imp;m;b}^{2*} = \frac{1}{n-1} \sum_{i=1}^n (y_{imp;m;b;i}^* - \overline{y_{imp;m;b}^*})^2$$

où $y_{imp;m;b;i}^*$ représente la i -ème d'observation de l'échantillon imputé b du bootstrap du jeu de données m et $\overline{y_{imp;m;b}^*} = \frac{1}{n} \sum_{i=1}^n y_{imp;m;b;i}^*$.

Nous obtenons, $s_{imp;m}^{2*} = [s_{imp;m;1}^{2*}, \dots, s_{imp;m;B}^{2*}]^T$ qui est la distribution des estimateurs de $s_{imp;m}^2$.

La variance des estimateurs de s_{imp}^2 est obtenue en calculant la variance de $s_{imp;m}^{2*}$, comme suit :

$$Var^*(s_{imp}^{2*})_m = Var^*(s_{imp;m}^{2*}) = \frac{1}{B-1} \sum_{b=1}^B (s_{imp;m;b}^{2*} - \overline{s_{imp;m}^{2*}})^2 \quad (5)$$

où $\overline{s_{imp;m}^{2*}} = \frac{1}{B} \sum_{b=1}^B s_{imp;m;b}^{2*}$.

Nous obtenons, $Var^*(s_{imp}^{2*}) = [Var^*(s_{imp}^{2*})_1, \dots, Var^*(s_{imp}^{2*})_M]^T$, qui est la distribution des estimateurs bootstrap de la variance de s_{imp}^2 .

6.3 Critères d'évaluation

Pour comparer l'efficacité des estimateurs bootstrap des différentes combinaisons, nous utilisons le biais absolu et le biais relatif.

Le biais absolu de l'estimateur bootstrap du biais de s_{imp}^2 (la distribution des estimateurs de σ^2) peut être formulé en comparant l'espérance des estimateurs bootstrap du biais de s_{imp}^2 avec le biais de s_{imp}^2 , et en appliquant la valeur absolue à cette différence. Le calcul du biais absolu implique plusieurs étapes importantes.

Étape 1 : Calcul du biais de s_{imp}^2

Le biais de s_{imp}^2 est donné par la différence entre l'espérance de s_{imp}^2 et σ^2 :

$$Biais(s_{imp}^2) = E(s_{imp}^2) - \sigma^2$$

où $E(s_{imp}^2)$ est l'espérance de s_{imp}^2 , approximée en calculant la moyenne des valeurs obtenues de s_{imp}^2 :

$$E(s_{imp}^2) \approx \hat{E}(s_{imp}^2) = \frac{1}{M} \sum_{m=1}^M s_{imp;m}^2$$

Étape 2 : Calcul des estimateurs bootstrap du biais de s_{imp}^2

L'estimateur du biais de s_{imp}^2 est calculé pour chaque jeu de donnée comme suit :

$$\widehat{Biais}(s_{imp}^2)_m = \widehat{Biais}(s_{imp;m}^2) = E^*(s_{imp;m}^{2*}) - s_{imp;m}^2$$

où $E^*(s_{imp;m}^{2*})$ est l'espérance de $s_{imp;m}^{2*}$, approximée en calculant la moyenne des valeurs obtenues de $s_{imp;m;b}^{2*}$:

$$E^*(s_{imp;m}^{2*}) \approx \hat{E}^*(s_{imp;m}^{2*}) = \frac{1}{B} \sum_{b=1}^B s_{imp;m;b}^{2*}.$$

Nous avons une distribution d'estimateur de biais de s_{imp}^2 , $\widehat{Biais}(s_{imp}^2) = [\widehat{Biais}(s_{imp}^2)_1, \dots, \widehat{Biais}(s_{imp}^2)_M]^T$

Étape 3 : Calcul de l'espérance des estimateurs bootstrap du biais s_{imp}^2

L'espérance des estimateurs bootstrap du biais s_{imp}^2 est approximée en calculant la moyenne des estimateurs bootstrap du biais s_{imp}^2 .

$$E(\widehat{Biais}(s_{imp}^2)) \approx \hat{E}(\widehat{Biais}(s_{imp}^2)) = \frac{1}{M} \sum_{m=1}^M \widehat{Biais}(s_{imp}^2)_m$$

Étape 4 : En combinant les étapes 1,2 et 3, nous obtenons le biais absolu de l'estimateur bootstrap du biais de s_{imp}^2 :

$$Biais_1 = |Biais(\widehat{Biais}(s_{imp}^2))| = |E(\widehat{Biais}(s_{imp}^2)) - Biais(s_{imp}^2)|.$$

Le biais relatif de l'estimateur bootstrap de la variance de s_{imp}^2 est une mesure de l'écart absolu entre l'espérance de l'estimateur bootstrap de la variance de s_{imp}^2 et la variance s_{imp}^2 , normalisé par la variance de s_{imp}^2 . Il est exprimé comme suit :

Étape 1 : Calcul de l'espérance de l'estimateur bootstrap de la variance de s_{imp}^2

L'espérance de l'estimateur bootstrap de la variance de s_{imp}^2 est approximée en calculant la moyenne des estimateurs bootstrap de la variance de s_{imp}^2 calculés à l'équation (6).

$$E(Var^*(s_{imp}^{2*})) \approx \frac{1}{M} \sum_{m=1}^M Var^*(s_{imp}^{2*})_m.$$

Étape 2 : Calcul du biais relatif de l'estimateur bootstrap de la variance de s_{imp}^2

Ce biais relatif est calculé comme suit :

$$Biais_2 = \frac{|E(Var^*(s_{imp}^{2*})) - Var(s_{imp}^2)|}{Var(s_{imp}^2)}$$

où $Var(s_{imp}^2)$ vient de l'équation 5.

7. Résultat

Nous réalisons la simulation en suivant les combinaisons présentées dans le Tableau 1. Les variances populationnelles, σ^2 , étaient de 221,24 pour $n = 40$ et de 180,65 pour $n = 100$. Comme prévu, la variance populationnelle est plus petite pour $n = 100$ comparée à $n = 40$, reflétant le schéma habituel selon lequel des tailles d'échantillon plus grandes ont tendance à produire des variances plus faibles.

Tableau 2. Résultats pour le biais absolu de l'estimateur bootstrap du biais de s_{imp}^2 pour nos 6 combinaisons

Prob. de manque	$n = 40$			$n = 100$		
	$E(\widehat{Biais}(s_{imp}^2))$	$Biais(s_{imp}^2)$	$Biais_1$	$E(\widehat{Biais}(s_{imp}^2))$	$Biais(s_{imp}^2)$	$Biais_1$
$p = 0,1$	-5,67	-2,67	3,00	-2,23	-0,43	1,80
$p = 0,2$	-6,30	-11,62	5,32	-2,20	-3,93	1,73
$p = 0,3$	-8,74	-20,04	11,30	-3,56	-6,04	2,48

Abréviations: n = Taille d'échantillon, Prob. de manque = Probabilité de manquement

Le Tableau 2 présente les résultats du biais absolu du biais estimé de s_{imp}^2 ($Bias_1$).

Pour toutes les probabilités de données manquantes, les valeurs de $Bias_1$ sont plus faibles pour $n = 100$ comparées à $n = 40$. Cette observation est probablement due à la variance plus faible associée aux tailles d'échantillon plus grandes, ce qui conduit à des estimations plus précises.

Une tendance notable est le comportement de $E(\widehat{Biais}(s_{imp}^2))$ comparé à $Biais(s_{imp}^2)$. La valeur espérée du biais estimé, $E(\widehat{Biais}(s_{imp}^2))$, ainsi que $Biais(s_{imp}^2)$, augmentent négativement à mesure que la probabilité de données manquantes augmente, bien que $E(\widehat{Biais}(s_{imp}^2))$ soit plus stable et que $Biais(s_{imp}^2)$ soit plus volatile. Cette différence en stabilité peut être attribuée aux méthodes de calcul. En effet, $\widehat{Biais}(s_{imp}^2)$ est dérivé de la différence entre le biais estimé de s_{imp}^2 , obtenu au niveau du bootstrap, et s_{imp}^2 obtenu à partir de y_{imp} pour chaque jeu de données. Bien que les niveaux soient différents, les deux sont calculés à partir des observations imputées. En conséquence, $E(\widehat{Biais}(s_{imp}^2))$ montre une certaine stabilité. En revanche, $Biais(s_{imp}^2)$ est calculé comme la différence entre la valeur espérée de s_{imp}^2 et la

variance populationnelle fixe, σ^2 . À mesure que la probabilité de données manquantes augmente, $Biais(s_{imp}^2)$ devient fortement biaisé négativement, car SPMM construit des modèles ajustés basés sur les données observées et impute une donnée originale à partir de la valeur ajustée la plus proche. Avec l'augmentation des données manquantes, y_{imp} réduit sa variabilité, ce qui conduit une augmentation négative de $Biais(s_{imp}^2)$.

Une autre observation clé est qu'aux $p = 0,1$ et $p = 0,2$, le $Bias_1$ est relativement proche pour les deux tailles d'échantillons, tandis qu'à $p = 0,3$ le $Bias_1$ est relativement pire que les des autres probabilités de manquement. Cette observation implique que les valeurs de $Bias_1$ pour $p = 0,1$ et $p = 0,2$ sont également fiables et qu'au-delà de $p = 0,2$, comme le $Bias_1$ augmente considérablement, l'utilisation de $E(\widehat{Biais}(s_{imp}^2))$ comme estimateur n'est plus appropriée.

Tableau 3. Résultats pour le biais relatif de l'estimateur bootstrap de la variance de s_{imp}^2 pour nos 6 combinaisons

Prob. de manque	$n = 40$				$n = 100$			
	$E(\widehat{Var}(s_{imp}^2))$	$Var(s_{imp}^2)$	$Biais Absolue$	$Biais_2$	$E(\widehat{Var}(s_{imp}^2))$	$Var(s_{imp}^2)$	$Biais Absolue$	$Biais_2$
$p = 0,1$	3092,38	661,43	2430,95	3,68	735,32	177,15	558,17	3,15
$p = 0,2$	3222,39	918,00	2304,39	2,51	774,79	259,42	515,36	1,99
$p = 0,3$	3335,19	1301,17	2034,02	1,56	823,75	313,70	510,05	1,63

Abréviations: n = Taille d'échantillon, Prob. de manque = Probabilité de manquement, Biais Absolue = $|E(Var^*(s_{imp}^2)) - Var(s_{imp}^2)|$

Le Tableau 3 résume le biais relatif, $Bias_2$, de la variance estimée de s_{imp}^2 . Le biais absolu de la variance estimée est généralement plus faible pour $n = 100$ que pour $n = 40$, conformément à la réduction de la variance lorsque la taille de l'échantillon augmente.

Contrairement à nos attentes, $Bias_2$ diminue à mesure que le taux de données manquantes augmente. Cela s'explique par le fait que la variance espérée de s_{imp}^2 estimée est plus stable que la variance de s_{imp}^2 . Alors que la variance de s_{imp}^2 augmente rapidement, le numérateur de $Bias_2$ qui est le biais absolu de la variance espérée, diminue, et est divisé par un dénominateur qui augmente avec des probabilités de données manquantes plus élevées. Cette volatilité qui existe dans $Var(s_{imp}^2)$ à mesure que la probabilité de manquement augmente, combiné avec la stabilité de $E(\widehat{Var}(s_{imp}^2))$ résulte à des valeurs de $Biais_2$ qui décroissent assez rapidement à mesure que la probabilité de manquement augmente.

Comme mentionné ci-dessus, la valeur espérée de la variance estimée de s_{imp}^2 est beaucoup plus grande que la variance de s_{imp}^2 . Cela peut s'expliquer par l'incertitude concernant le nombre et la répartition des observations manquantes dans les échantillons bootstrap, ce qui ajoute à la variabilité de la méthode d'imputation.

8. Conclusion

Dans cette étude, nous avons examiné la performance de l'estimation du biais et de la variance de l'estimateur de variance, calculé à partir d'un ensemble de données incluant des observations

imputées, pour différentes tailles d'échantillon et probabilités de données manquantes. Pour évaluer ces performances, nous concentrons notre attention sur le biais absolu du biais estimé de s_{imp}^2 ($Bias_1$) et le biais relatif de la variance estimée de s_{imp}^2 ($Bias_2$). Nous constatons que des tailles d'échantillon plus grandes ($n = 100$) donnent systématiquement des valeurs de $Bias_1$ plus petites comparées aux tailles d'échantillon plus petites ($n = 40$). De plus, nous observons que $p = 0,2$ agit comme un seuil pour utiliser l'estimateur du biais de s_{imp}^2 , en raison du fait que le $Bias_1$ est beaucoup plus grand pour $p = 0,3$ comparé à $p = 0,1$ et $p = 0,2$.

Fait intéressant, le $Bias_2$ diminuait à mesure que la probabilité de données manquantes augmente, et ce, pour les deux tailles d'échantillon. Cette observation contre-intuitive pourrait refléter l'impact de lissage introduit par l'imputation aux niveaux élevés de données manquantes. Cependant, la variance estimée de s_{imp}^2 est systématiquement plus grande que $Var(s_{imp}^2)$ probablement en raison de la variabilité supplémentaire introduite par l'échantillonnage bootstrap. Malgré ces tendances, les différences de $Bias_2$ entre les tailles d'échantillon étaient minimales. Cette observation confirme la définition du biais relatif, qui permet de neutraliser l'effet de la taille d'échantillon grâce à la division par $Var(s_{imp}^2)$.

Dans l'ensemble, ces résultats mettent en évidence l'importance de prendre en compte les probabilités de données manquantes et les tailles d'échantillon lors de l'estimation du biais de l'estimateur de variance et de la variance de l'estimateur de variance pour des données imputées. Ils apportent des perspectives précieuses sur le comportement de ces estimateurs dans des conditions variables, et permettent de faire des choix méthodologiques plus éclairés dans les études futures. Par ailleurs, les résultats soulignent la nécessité d'évaluer soigneusement les performances des méthodes d'imputation et leurs interactions avec la méthode bootstrap.

Des recherches futures pourraient explorer des approches alternatives pour réduire la surestimation de la variance observée dans les méthodes basées sur le bootstrap, en particulier dans des scénarios de forte proportion de données manquantes. De plus, développer des méthodes permettant d'évaluer le biais du biais estimé de la variance indépendamment des effets de la taille d'échantillon améliorerait significativement la robustesse de ces analyses. Enfin, évaluer la généralisation de ces résultats à d'autres techniques d'imputation, telles que l'imputation multiple ou les méthodes basées sur l'apprentissage automatique, pourrait étendre davantage l'applicabilité de ces perspectives.

Bibliographie

1. Schomaker, M., & Heumann, C. (2018). Bootstrap inference when using multiple imputation. *Statistics in Medicine*, 37(14), 2252–2266.
<https://doi.org/10.1002/sim.7654>
2. Bartlett, J. W., & Hughes, R. A. (2020). Bootstrap inference for multiple imputation under uncongeniality and misspecification. *Statistical Methods in Medical Research*, 29(12), 3533–3546. <https://doi.org/10.1177/0962280220932189>
3. Rubin, D. B. (1976). Inference and missing data. *Biometrika*, 63(3), 581–592.
<https://doi.org/10.2307/2335739>
4. Zhang, X. (2023). How to generate missing data for simulation studies. (2023). *The Quantitative Methods for Psychology*, 19(2), 100–122.
<https://doi.org/10.20982/tqmp.19.2.p100>
5. Andridge, R. R., & Little, R. J. A. (2010). A review of hot deck imputation for survey non-response. *International Statistical Review*, 78(1), 40–64.
<https://doi.org/10.1111/j.1751-5823.2010.00103.x>